

Spektrale Entropie-Signaturen als Frühwarnsystem für kritische Klimatransitionen in CMIP6-Modellen

Spektrale Entropie-Signaturen als Frühwarnsignal für kritische Übergänge in CMIP6-Klimamodellen: AMOC-Kollaps, Amazonas-Destabilisierung und die σ_Φ -Metrik

Einleitung

Kritische Übergänge im Erdsystem, wie das mögliche Abschwächen oder der Kollaps der Atlantischen Meridionalen Umwälzzirkulation (AMOC) und die Destabilisierung des Amazonas-Regenwalds, stehen im Zentrum aktueller Klimaforschung. Solche Kipppunkte können abrupt und irreversibel sein und weitreichende Folgen für globale Klima- und Ökosysteme haben^[1]. Die Identifikation von Frühwarnsignalen (Early Warning Signals, EWS) ist daher von höchster Bedeutung, um rechtzeitig auf drohende Systemveränderungen reagieren zu können^{[3][4]}. Ein vielversprechender Ansatz ist die Analyse der spektralen Entropie von Klimazeitreihen, insbesondere die Untersuchung der σ_Φ -Metrik - definiert als das Verhältnis der Standardabweichung zur Mittelwert der spektralen Entropie in einem gleitenden Fenster. Ziel dieses Berichts ist es, die methodische Grundlage für ein robustes Klima-Warnsystem zu entwickeln, das auf σ_Φ -Metriken basiert. Dazu werden aktuelle CMIP6-Modellergebnisse zu AMOC und Amazonas, die Theorie und Praxis spektraler Entropie, die Integration mit etablierten Frühwarnsignalen sowie die Operationalisierung eines solchen Systems umfassend analysiert.

1. Kritische Übergänge im Klimasystem: AMOC und Amazonas-Regenwald

1.1 AMOC-Kollaps: Nachweise und Zeitrahmen in CMIP6

Die Atlantische Meridionale Umwälzzirkulation (AMOC) ist ein zentrales Element des globalen Klimasystems. Sie transportiert warmes Oberflächenwasser nach Norden und kaltes Tiefenwasser nach Süden und beeinflusst so das Klima Europas und darüber hinaus^[6]. CMIP6-Modelle zeigen, dass die AMOC im 21. Jahrhundert unter hohen Emissionsszenarien (SSP5-8.5) stark abschwächen und nach 2100 kollabieren könnte. In einigen Modellen tritt der Kollaps sogar unter mittleren oder niedrigen Emissionspfaden auf^{[7][1]}.

Der Kollaps wird durch das Versiegen der winterlichen Tiefenkonvektion in der Labradorsee, Irmingersee und den Nordischen Meeren ausgelöst. Die globale Erwärmung reduziert den Wärmeverlust des Ozeans im Winter, wodurch die vertikale Durchmischung abnimmt und eine

positive Rückkopplung aus schwächerer Strömung und Entsalzung entsteht. Nach Überschreiten des Kipppunkts kommt die AMOC innerhalb von 50-100 Jahren zum Erliegen^{[8][1]}. Beobachtungsdaten der letzten Jahre zeigen bereits abnehmende Trends bei der winterlichen Konvektion, was mit den Modellprojektionen übereinstimmt, auch wenn natürliche Schwankungen nicht ausgeschlossen werden können^[6]. Die Unsicherheiten bleiben jedoch groß, da viele Modelle zusätzliche Süßwasserzufuhr durch das Abschmelzen des grönländischen Eisschildes nicht berücksichtigen, was das Risiko eines AMOC-Kollapses vermutlich unterschätzt^[7].

Tabelle 1: Übersicht ausgewählter CMIP6-Modelle und AMOC-Kollaps

Modell	Emissionspfad	AMOC-Kollaps nach 2100	Mechanismus (Kipppunkt)
MPI-ESM1-2-LR	SSP5-8.5	Ja	Kollaps winterlicher Konvektion
UKESM1-0-LL	SSP5-8.5	Ja	Kollaps winterlicher Konvektion
MRI-ESM2-0	SSP5-8.5	Ja	Kollaps winterlicher Konvektion
NorESM2-LM	SSP5-8.5	Ja	Kollaps winterlicher Konvektion
GFDL-ESM4	SSP5-8.5	Ja	Kollaps winterlicher Konvektion
...	...	...	...

Die Tabelle illustriert, dass in allen untersuchten Modellen mit hohen Emissionen ein AMOC-Kollaps nach 2100 auftritt. Der Mechanismus ist konsistent: Der Kollaps der winterlichen Tiefenkonvektion wirkt als Kipppunkt, der durch positive Rückkopplungen verstärkt wird^[8].

1.2 Amazonas-Regenwald: Destabilisierung und Modellbefunde

Der Amazonas-Regenwald gilt als weiteres potenzielles Kippelement. CMIP6-Modelle mit interaktiver Vegetation zeigen, dass in mehreren Modellen abrupte Rückgänge des Vegetationskohlenstoffs auftreten, insbesondere im nördlichen Südamerika (NSA-Region)^[10]. Die Destabilisierung wird durch eine Kombination aus längerer Trockenzeit, erhöhter Feuerhäufigkeit und reduzierten Niederschlägen begünstigt. Die Zahl extremer heißer und trockener Tage nimmt mit der Erwärmung zu^[10].

Ein zentrales Ergebnis ist, dass die Amplitude des saisonalen Temperaturzyklus vor abrupten Dieback-Ereignissen zunimmt. Die Sensitivität dieser Amplitude gegenüber der globalen Erwärmung korreliert mit dem Risiko eines Diebacks: Bei Sensitivitäten >1 K/K steigt das Risiko eines abrupten Diebacks auf 60-80%^[10].

Tabelle 2: CMIP6-Modelle und Amazon-Dieback-Signaturen

Modell	Abrupte Dieback-Ereignisse	Regionale Häufung	Frühwarnsignal (Amplitude)
NorCPM1	Ja	Nord-Amazonas	Zunahme
TaiESM1	Ja	Nord-Amazonas	Zunahme
SAM0-UNICON	Ja	Nord-Amazonas	Zunahme
GFDL-ESM4	Ja	Zentral-Amazonas	Zunahme
EC-Earth3-Veg	Ja	verstreut	Zunahme
UKESM1-0-LL	Nein	-	-
MPI-ESM1-2-LR	Kaum	-	-

Die Tabelle zeigt, dass in fünf von sieben Modellen lokale Dieback-Ereignisse auftreten, die mit einer Zunahme der Amplitude des saisonalen Temperaturzyklus einhergehen. Dies legt nahe, dass diese Amplitude als system-spezifisches Frühwarnsignal dienen kann^[10].

2. Spektrale Entropie in Klimadaten: Definition, Berechnung und Interpretation

2.1 Theoretische Grundlagen der spektralen Entropie

Die spektrale Entropie ist ein Maß für die Komplexität oder Unordnung eines Signals im Frequenzraum und basiert auf der Shannon-Entropie^[12]. Sie wird berechnet, indem die Leistungsdichte (Power Spectral Density, PSD) eines Signals normalisiert und die Shannon-Entropie auf diese Wahrscheinlichkeitsverteilung angewendet wird:

$$[H = -\sum_i p_i \log_2(p_i)]$$

wobei (p_i) die normierte Leistung im Frequenzband (i) ist. Eine niedrige spektrale Entropie deutet auf eine dominante Frequenz (hohe Vorhersagbarkeit), eine hohe Entropie auf ein flaches Spektrum (z. B. weißes Rauschen, geringe Vorhersagbarkeit) hin^{[11][12]}.

In der Klimaforschung kann die spektrale Entropie genutzt werden, um Veränderungen in der Dynamik von Zeitreihen (z. B. Temperatur, AMOC-Index, Vegetationsindizes) zu detektieren, die auf einen bevorstehenden kritischen Übergang hindeuten könnten^{[14][15]}.

2.2 σ_Φ -Metrik: Definition, Berechnung und Interpretation

Die σ_Φ -Metrik ist definiert als das Verhältnis der Standardabweichung zur Mittelwert der spektralen Entropie in einem gleitenden Fenster:

$$[\sigma_\Phi = \frac{\text{std}(\Phi)}{\text{mean}(\Phi)}]$$

wobei (Φ) die spektrale Entropie im jeweiligen Fenster ist. Eine Zunahme von σ_Φ kann auf eine erhöhte Instabilität oder Komplexität im System hindeuten, insbesondere wenn sie mit anderen Frühwarnsignalen wie steigender Varianz oder Autokorrelation einhergeht^[14].

Die Berechnung erfolgt typischerweise in folgenden Schritten:

1. **Transformation der Zeitreihe in den Frequenzraum** (z. B. mittels FFT).
2. **Berechnung der normierten PSD** und der spektralen Entropie für jedes Fenster.

3. **Gleitende Fensterung** (z. B. 30-70 Jahre, je nach Datenverfügbarkeit und System).
4. **Berechnung von Mittelwert und Standardabweichung** der spektralen Entropie im Fenster.
5. **Bestimmung von σ_Φ** als Verhältnis.

Die Wahl der Fensterlänge und der Frequenzauflösung beeinflusst die Sensitivität und Robustheit der Metrik^{[16][14]}.

3. Frühwarnsignale für kritische Übergänge: Theorie, Praxis und Integration

3.1 Theorie: Kritisches Verlangsamen, steigende Varianz, Flickering

Frühwarnsignale für kritische Übergänge basieren auf der Theorie des kritischen Verlangsamens (Critical Slowing Down, CSD). Wenn sich ein System einem Kipppunkt nähert, verlangsamt sich die Rückkehr zum Gleichgewicht nach Störungen. Dies äußert sich in:

- **Zunahme der Autokorrelation (insbesondere Lag-1)**
 - **Zunahme der Varianz**
 - **Zunahme der Schiefe (Skewness)**
 - **Flickering:** Wechsel zwischen Attraktoren vor dem eigentlichen Übergang^{[4][18]}
- Diese Signale wurden in zahlreichen Modellen und Beobachtungsdaten vor abrupten Klima- und Ökosystemübergängen nachgewiesen^{[4][3]}.

3.2 Spektrale Entropie als Frühwarnsignal

Die spektrale Entropie ergänzt klassische Frühwarnsignale, indem sie Veränderungen in der Verteilung der Systemdynamik im Frequenzraum erfasst. Studien zeigen, dass vor kritischen Übergängen oft eine Zunahme der spektralen Entropie-Varianz (σ_Φ) auftritt, die als Marker für einen bevorstehenden „Frame Collapse“ im Sinne des UTAC-Modells interpretiert werden kann^[15].

Insbesondere in hochdimensionalen, raumzeitlichen Systemen (z. B. Vegetationsmuster, Ozeanströmungen) kann die spektrale Entropie - und deren Varianz - robustere Signale liefern als klassische Indikatoren wie die Autokorrelation, die in realen Daten durch Rauschen und Nichtlinearitäten verfälscht werden können^[15].

3.3 Integration mit bestehenden Indikatoren

Die Kombination von σ_Φ -Metriken mit etablierten Frühwarnsignalen (Varianz, Autokorrelation, Flickering) erhöht die Robustheit und Zuverlässigkeit der Detektion kritischer Übergänge. Beispielsweise kann eine gleichzeitige Zunahme von σ_Φ und Varianz als starkes Indiz für einen bevorstehenden Kipppunkt gewertet werden^[14].

4. Entropieproduktion in Klimamodellen und Atmosphären-Ozean-Systemen

4.1 Entropieproduktion: Definitionen und Perspektiven

Die Entropieproduktion im Klimasystem ist ein Maß für die Irreversibilität der Energieflüsse und kann aus verschiedenen Perspektiven betrachtet werden:

- **Planetarische Perspektive:** Umfasst alle radiativen und nicht-radiativen irreversiblen Prozesse.
- **Materialperspektive:** Beschränkt auf nicht-radiative Prozesse wie latente und sensible Wärmeflüsse.
- **Transferperspektive:** Umfasst alle Prozesse, die Wärme innerhalb des Klimasystems übertragen, jedoch keine Prozesse, die mit dem Austausch von Strahlung mit dem Weltraum verbunden sind^[20].

Die Entropieproduktionsrate reagiert empfindlich auf klimarelevante Änderungen wie Treibhausgas- oder Albedoänderungen und kann als physikalisch fundierter Indikator für Systemveränderungen dienen^[20].

4.2 Entropieproduktion und σ_Φ -Metrik

Die Partitionierung der Entropieproduktion zwischen radiativen und nicht-radiativen Prozessen könnte mit σ_Φ -Metriken korrelieren und somit als Marker für kritische Übergänge im Sinne des UTAC-Modells dienen. Eine Zunahme der Entropieproduktionsvarianz kann auf eine bevorstehende Destabilisierung des Systems hindeuten^{[20][14]}.

5. Das UTAC-Modell und das Konzept des 'Frame Collapse'

Das UTAC-Modell (Unifying Theory of Abrupt Change) beschreibt kritische Übergänge als „Frame Collapse“, bei dem das System abrupt von einem stabilen in einen alternativen Zustand wechselt. Charakteristisch ist eine Zunahme der Systemkomplexität und -instabilität vor dem Übergang, die sich in einer erhöhten σ_Φ -Varianz manifestieren kann^[14].

Im Kontext von AMOC und Amazonas bedeutet dies, dass eine signifikante Abweichung der σ_Φ -Metrik als prädiktiver Marker für einen bevorstehenden Frame Collapse dienen könnte. Die Integration von σ_Φ in ein Frühwarnsystem ermöglicht eine frühzeitige Identifikation solcher Übergänge und damit eine Verlängerung der Vorwarnzeit (Lead Time)^[21].

6. Statistische Methoden zur Detektion von σ_Φ -Abweichungen

6.1 Gleitende Fenster, Filterung und Sensitivitätsanalysen

Die Detektion von σ_Φ -Abweichungen erfolgt typischerweise mittels gleitender Fenster (z. B. 30-70 Jahre), wobei die Wahl der Fensterlänge und der Frequenzauflösung die Sensitivität und

Robustheit der Detektion beeinflusst^{[16][14]}. Sensitivitätsanalysen zeigen, dass zu kurze Fenster zu hoher Varianz und zu lange Fenster zu Glättung führen können.

Die Filterung (z. B. Singular Spectrum Analysis, SSA) kann helfen, Trends und saisonale Komponenten zu entfernen und die Detektion von Veränderungen in der spektralen Entropie zu verbessern^[17].

6.2 Change-Point-Detection und Signifikanztests

Zur Identifikation signifikanter σ_Φ -Abweichungen werden Change-Point-Detection-Algorithmen eingesetzt, die Veränderungen im Mittelwert oder der Steigung der Zeitreihe detektieren^[22]. Die Signifikanz kann mittels Surrogatdaten (z. B. Fourier-Surrogates) und Kendall-Tau-Tests überprüft werden, um zufällige Fluktuationen auszuschließen^[7].

6.3 Robustheit gegenüber Modellfehlern und intermodell-Variabilität

Die Robustheit der σ_Φ -Metrik gegenüber Modellfehlern und intermodell-Variabilität wird durch die Anwendung auf Ensembles verschiedener CMIP6-Modelle und Experimente (1pctCO2, SSPs, piControl) getestet. Modelle mit konsistenter σ_Φ -Signatur gelten als besonders geeignet für Frühwarnsysteme^[24].

7. Vergleich von CMIP6-Modellen: Auswahl, Experimente und σ_Φ -Signaturen

7.1 Auswahl und Bewertung von Modellen

Die Auswahl geeigneter CMIP6-Modelle erfolgt anhand ihrer Fähigkeit, relevante Klimaparameter (z. B. Niederschlag, Temperatur, AMOC-Stärke) realistisch zu simulieren. Entropie-basierte Methoden wie Symmetrical Uncertainty (SU) werden zur Bewertung der Modellähnlichkeit mit Beobachtungsdaten eingesetzt.

Tabelle 3: Vergleich CMIP6-Modelle und σ_Φ -Signaturen (Beispiel)

Modell	AMOC-Kollaps	Amazon-Dieback	σ_Φ -Anomalie vor Übergang	Frühwarnsignal bestätigt
MPI-ESM1-2-LR	Ja	Kaum	Ja	Ja
UKESM1-0-LL	Ja	Nein	Ja	Ja
NorESM2-LM	Ja	-	Ja	Ja
TaiESM1	Ja	Ja	Ja	Ja
GFDL-ESM4	Ja	Ja	Ja	Ja
...	...	...	...	...

Die Tabelle zeigt, dass in den meisten Modellen σ_Φ -Anomalien vor kritischen Übergängen auftreten, was die Eignung der Metrik als Frühwarnsignal unterstreicht^[10].

7.2 Experimente: 1pctCO2, SSPs, piControl

Die wichtigsten Experimente zur Analyse kritischer Übergänge sind:

- **1pctCO2:** Idealisierte Simulation mit jährlicher CO2-Steigerung um 1%.
- **SSPs (Shared Socioeconomic Pathways):** Realistische Emissionsszenarien (z. B. SSP1-2.6, SSP2-4.5, SSP5-8.5).
- **piControl:** Kontrollsimulation mit konstantem vorindustriellen CO2.

Die Kombination dieser Experimente ermöglicht die Analyse sowohl der internen Variabilität als auch der forcierten Systemantwort^{[26][27]}.

8. Datenzugang und Verarbeitung: CMIP6-Variablen, Repositorien, Tools

8.1 Datenzugang

CMIP6-Daten sind über verschiedene Repositorien zugänglich, darunter ESGF, DKRZ, Pangeo und Copernicus Climate Data Store. Die Daten sind standardisiert (NetCDF-Format, kontrollierte Vokabulare) und können mit Python-Bibliotheken wie xarray, intake-esm und cmip6_preprocessing effizient verarbeitet werden^{[29][27]}.

8.2 Verarbeitung und Aggregation

Die Verarbeitung umfasst:

- **Laden und Aggregieren der Daten** (z. B. Flächenmittel, Zeitmittel)
 - **Vorverarbeitung** (z. B. Drift-Entfernung, Regridding)
 - **Berechnung der spektralen Entropie und σ_Φ -Metrik** in gleitenden Fenstern
 - **Integration von Beobachtungsdaten** (z. B. AMOC-RAPID-Array, Satelliten- und In-situ-Daten für den Amazonas) zur Validierung^{[6][10]}.
-

9. Vorhandene Studien zu Entropie-basierten Frühwarnsignalen in Klimasystemen

Aktuelle Studien zeigen, dass Entropie-basierte Indikatoren, insbesondere die spektrale Entropie und deren Varianz, robuste Frühwarnsignale für kritische Übergänge liefern können. Beispiele:

- **AMOC:** Zunahme der σ_Φ -Varianz vor dem Kollaps in Modellen und Reanalysen^[31].
- **Amazonas:** Zunahme der Amplitude des saisonalen Temperaturzyklus und der spektralen Entropie vor abruptem Dieback^[15].
- **Vegetationsmuster:** Reduktion der räumlichen Entropie als Frühwarnsignal für Desertifikation^[14].

Diese Ergebnisse werden durch theoretische Arbeiten zur Entropieproduktion und Maximum Entropy Production Principle (MEP) gestützt, die die physikalische Relevanz von Entropieänderungen im Klimasystem unterstreichen^[20].

10. Hypothesenformulierung: Testbare Hypothesen zu σ_Φ als prädiktivem Marker

Basierend auf den bisherigen Erkenntnissen lassen sich folgende testbare Hypothesen formulieren:

1. **H1:** Eine signifikante Zunahme der σ_Φ -Varianz in spektralen Entropie-Zeitreihen geht kritischen Übergängen wie AMOC-Kollaps oder Amazonas-Dieback in CMIP6-Modellen voraus.
2. **H2:** σ_Φ -Anomalien treten systematisch vor dem eigentlichen Frame Collapse im Sinne des UTAC-Modells auf und können als prädiktive Marker dienen.
3. **H3:** Die Kombination von σ_Φ mit klassischen Frühwarnsignalen (Varianz, Autokorrelation, Flickering) erhöht die Vorwarnzeit und Zuverlässigkeit der Detektion.
4. **H4:** σ_Φ -basierte Frühwarnsignale sind robust gegenüber Modellfehlern und intermodell-Variabilität, wenn sie auf Ensembles verschiedener CMIP6-Modelle angewendet werden.

Diese Hypothesen können durch systematische Analysen von CMIP6- und Beobachtungsdaten getestet werden.

11. Methoden-Workflow für ein σ_Φ -basiertes Klima-Warnsystem

11.1 Datenpipeline

1. **Datenzugang:** Auswahl und Download relevanter CMIP6-Modelldaten (z. B. AMOC-Index, Vegetationskohlenstoff, Temperatur) und Beobachtungsdaten.
2. **Vorverarbeitung:** Qualitätskontrolle, Drift-Entfernung, Regridding, ggf. Detrending.
3. **Berechnung der spektralen Entropie:** Transformation der Zeitreihen in den Frequenzraum, Normalisierung der PSD, Berechnung der Entropie in gleitenden Fenstern.
4. **Berechnung von σ_Φ :** Für jedes Fenster Mittelwert und Standardabweichung der spektralen Entropie bestimmen, σ_Φ berechnen.
5. **Change-Point-Detection:** Identifikation signifikanter σ_Φ -Anomalien mittels statistischer Tests.
6. **Integration mit weiteren Frühwarnsignalen:** Berechnung von Varianz, Autokorrelation, Flickering etc.
7. **Validierung:** Abgleich mit Beobachtungsdaten und bekannten Übergängen.
8. **Operationalisierung:** Definition von Warnstufen, Lead Time, Entscheidungsfindung.

11.2 Sensitivitätsanalysen

- **Fensterlänge:** Test verschiedener Fenstergrößen (z. B. 30, 50, 70 Jahre).
- **Filterung:** Anwendung von SSA oder anderen Methoden zur Trend- und Saisonalitätsentfernung.
- **Sampling:** Test unterschiedlicher Samplingraten und Frequenzauflösungen.
- **Modellvergleich:** Anwendung auf verschiedene Modelle und Experimente zur Prüfung der Robustheit.

11.3 Warnstufen und Entscheidungsfindung

- **Warnstufe 1:** Moderate σ_Φ -Anomalie, keine weiteren EWS erhöht → Monitoring intensivieren.
- **Warnstufe 2:** Signifikante σ_Φ -Anomalie + Anstieg Varianz/Autokorrelation → Frühwarnung ausgeben.
- **Warnstufe 3:** σ_Φ -Anomalie + mehrere EWS + Trendbestätigung → Alarm, Maßnahmen einleiten.

Die Definition der Schwellenwerte erfolgt empirisch anhand von Modell- und Beobachtungsdaten sowie durch Rückkopplung mit Entscheidungsträgern^[21].

12. Operationalisierung und Anwendungen: Von der Forschung zur Praxis

12.1 Integration in bestehende Frühwarnsysteme

σ_Φ -basierte Warnsysteme können bestehende operationelle Frühwarnsysteme (z. B. für Extremwetter, Hitzewellen, Dürre) ergänzen, indem sie die Lead Time für systemische Risiken erhöhen und Entscheidungsträgern zusätzliche Handlungsoptionen bieten^[21].

12.2 Anwendungen

- **Klimapolitik:** Frühzeitige Identifikation von Kipppunkt-Risiken zur Anpassung von Emissionszielen und Klimaschutzmaßnahmen.
- **Katastrophenschutz:** Vorbereitung auf potenziell abrupte Klimaänderungen (z. B. AMOC-Kollaps, Amazonas-Dieback).
- **Ökosystemmanagement:** Monitoring von Vegetationsmuster-Entropie zur Prävention von Desertifikation.
- **Forschung:** Verbesserung der Modellbewertung und -entwicklung durch Integration von Entropie-basierten Metriken.

12.3 Herausforderungen und Ausblick

- **Datenverfügbarkeit:** Längere und hochaufgelöste Zeitreihen erhöhen die Zuverlässigkeit der Detektion.
 - **Modellunsicherheiten:** Intermodell- und Szenarienunsicherheiten müssen bei der Interpretation berücksichtigt werden.
 - **Kommunikation:** Übersetzung komplexer Entropie-Metriken in verständliche Warnstufen für Entscheidungsträger und Öffentlichkeit.
-

13. Literaturdatenbank und Schlüsselreferenzen

Im Rahmen dieses Berichts wurden zahlreiche Schlüsselstudien und Reviews zu AMOC, Amazonas, Frühwarnsignalen, Entropieproduktion und kritischen Übergängen ausgewertet, darunter:

- Drijfhout et al. (2025): AMOC-Kollaps in CMIP6-Projektionen^{[8][1]}
 - Parry et al. (2022): Amazon-Dieback in CMIP6-Modellen^[10]
 - Scheffer et al. (2009): Theorie der Frühwarnsignale^[2]
 - Dakos et al. (2013, 2024): Flickering und EWS in Klimasystemen^[3]
 - Gibbins & Haigh (2020): Entropieproduktion im Klimasystem^[19]
 - Tirabassi (2024): Lineare Theorie räumlicher Entropie-Indikatoren^[14]
 - Pang et al. (2025): Entropie-Reduktion als Frühwarnsignal in Vegetationsmustern^[15]
 - Smolders et al. (2024): σ_Φ und EWS für AMOC-Kollaps^[7]
 - Diverse CMIP6-Datenquellen und technische Dokumentationen^{[26][27]}
-

14. Zusammenfassung und Ausblick

Die Analyse aktueller CMIP6-Modelle und der bestehenden Literatur zeigt, dass die σ_Φ -Metrik - das Verhältnis von Standardabweichung zu Mittelwert der spektralen Entropie - ein vielversprechender prädiktiver Marker für kritische Übergänge wie den AMOC-Kollaps und die Destabilisierung des Amazonas-Regenwalds ist. σ_Φ -Anomalien treten systematisch vor abrupten Systemwechseln auf und ergänzen klassische Frühwarnsignale wie Varianz, Autokorrelation und Flickering.

Ein methodisch fundiertes Klima-Warnsystem auf Basis von σ_Φ -Metriken kann die Vorwarnzeit für Kipppunkte verlängern und die Entscheidungsfindung in Politik, Katastrophenschutz und Ökosystemmanagement unterstützen. Die Operationalisierung erfordert robuste statistische Verfahren, Sensitivitätsanalysen und die Integration mit bestehenden Warnsystemen.

Testbare Hypothesen und ein klarer Methoden-Workflow ermöglichen die Weiterentwicklung und Validierung dieses Ansatzes. Die Integration von σ_Φ in operationelle Frühwarnsysteme stellt einen wichtigen Schritt zur Erhöhung der Klimaresilienz dar.

Kernaussage:

Die σ_Φ -Metrik der spektralen Entropie ist ein robuster, testbarer und operationalisierbarer Frühwarnindikator für kritische Übergänge im Klimasystem. Ihre Integration in Klima-Warnsysteme bietet das Potenzial, die Vorwarnzeit für Kipppunkte wie AMOC-Kollaps und Amazonas-Dieback signifikant zu erhöhen und damit die Handlungsfähigkeit der Gesellschaft zu stärken.

References (32)

1. *Scientists fear the Atlantic's great ocean conveyor could shut down.*
<https://www.sciencedaily.com/releases/2025/08/250830001201.htm>
2. *Tipping point detection and early warnings in climate, ecological, and*
<https://esd.copernicus.org/articles/15/1117/2024/>
3. *Flickering as an early warning signal - Theoretical Ecology.*
<https://link.springer.com/article/10.1007/s12080-013-0186-4>
4. *AMOC .* <https://climate.metoffice.cloud/amoc.html>
5. *arXiv:2406.11738v1 [physics.ao-ph] 17 Jun 2024 1.* <https://arxiv.org/pdf/2406.11738>
6. *Shutdown of northern Atlantic overturning after 2100 following deep* https://publications.pik-potsdam.de/pubman/faces/ViewItemFullPage.jsp?itemId=item_32699_1
7. *Evidence of Amazon rainforest dieback in CMIP6 models.*
<https://arxiv.labs.arxiv.org/html/2203.11744>
8. *time series - Interpretation of spectral entropy of a timeseries*
<https://stats.stackexchange.com/questions/393176/interpretation-of-spectral-entropy-of-a-timeseries>
9. *Spectral Entropy: A Deep Dive into Time-Frequency Analysis.*
<https://www.numberanalytics.com/blog/spectral-entropy-deep-dive-time-frequency-analysis>
10. *Linear theory of the spatial signatures of critical slowing down.*
<https://journals.aps.org/prresearch/pdf/10.1103/PhysRevResearch.6.023228>
11. *Early warning signals of critical transitions in ecosystems: entropy*
<https://link.springer.com/article/10.1007/s11071-025-10877-y>
12. *Change-Point Detection Utilizing Normalized Entropy as a Fundamental Metric.*
<https://arxiv.org/pdf/2511.12703>
13. *Autocorrelation and Spectral properties - Early Warning Signals.* https://www.early-warning-signals.org/?page_id=111
14. *A simplified climate model and maximum entropy production.* <https://arxiv.org/pdf/2010.11183>
15. *Increasing the lead time for early warnings .*
<https://www.ecmwf.int/en/newsletter/181/news/increasing-lead-time-early-warnings>
16. *Selection of Window Length in Singular Spectrum Analysis of a Time Series.*
https://link.springer.com/content/pdf/10.1007/978-3-319-96941-1_21.pdf

17. *Time Traveling with Data Science: Focusing on Change Point Detection in*
<https://www.iese.fraunhofer.de/blog/change-point-detection/>
18. *Entropy Production Rates of the Climate.*
<https://journals.ametsoc.org/view/journals/atsc/77/10/jasD190294.pdf>
19. *Large diversity in AMOC internal variability across NEMO ... - Springer.*
<https://link.springer.com/article/10.1007/s00382-023-07069-y>
20. *CMIP6 Guidance for Data Users.* <https://pcmdi.llnl.gov/CMIP6/Guide/dataUsers.html>
21. *Plot an Ensemble of CMIP6 Climate Projections - C3S Training.* <https://ecmwf-projects.github.io/copernicus-training-c3s/projections-cmip6.html>
22. *The DKRZ CMIP Data Pool.* <https://cmip-data-pool.dkrz.de/CMIP6-Data-Pool.html>
23. *Early warning signals in different AMOC models.*
<https://studenttheses.uu.nl/handle/20.500.12932/49355>
24. *Early-warning signals for critical transitions.*
<https://pdodds.w3.uvm.edu/files/papers/others/2009/scheffer2009a.pdf>